

O Método de Otsu para Processamento de Imagens

Engenharia Clínica e Processamento Digital de Imagens

12 de junho de 2026

O **Método de Otsu** é um algoritmo clássico e extremamente elegante de *limiarização global automática* (*automatic global thresholding*) no processamento de imagens. Proposto por Nobuyuki Otsu em 1979, o seu grande mérito é determinar o limiar ideal (k) baseado puramente na estatística do histograma da imagem, sem necessidade de intervenção humana.

A intuição por trás do método é simples: ele busca o limiar que divide o histograma da imagem em **duas classes** (fundo e objeto) de forma que essas duas classes fiquem o mais separadas/distintas possível. Matematicamente, isso é feito de duas maneiras equivalentes: **minimizando a variância dentro das classes** ou **maximizando a variância entre as classes**.

Focaremos na **maximização da variância entre as classes** (σ_B^2), que é o caminho computacionalmente mais eficiente.

1 A Estatística do Histograma

Considere uma imagem digital em tons de cinza com L níveis de cinza (normalmente $L = 256$, variando de 0 a 255). O número de pixels com o nível de cinza i é denotado por n_i . O número total de pixels na imagem é dado por N .

Primeiro, normalizamos o histograma para obter a **função de probabilidade** de cada nível de cinza:

$$p_i = \frac{n_i}{N}, \quad p_i \geq 0, \quad \sum_{i=0}^{L-1} p_i = 1 \quad (1)$$

Se escolhermos um limiar k (onde $0 \leq k < L - 1$), dividimos os pixels da imagem em duas classes distintas:

- C_0 (**Fundo**): Pixels com níveis de cinza no intervalo $[0, k]$.
- C_1 (**Objeto**): Pixels com níveis de cinza no intervalo $[k + 1, L - 1]$.

2 Pesos e Médias das Classes

Para avaliar a qualidade do limiar k , precisamos calcular a probabilidade de ocorrência (peso) e a média ponderada de cada classe.

2.1 Probabilidades (Pesos) das Classes

As probabilidades $\omega_0(k)$ e $\omega_1(k)$ indicam a proporção de pixels que pertencem a C_0 e C_1 , respectivamente:

$$\omega_0(k) = \sum_{i=0}^k p_i \quad (2)$$

$$\omega_1(k) = \sum_{i=k+1}^{L-1} p_i = 1 - \omega_0(k) \quad (3)$$

2.2 Médias das Classes

A média dos níveis de cinza para cada classe, denotadas por $\mu_0(k)$ e $\mu_1(k)$, são calculadas como:

$$\mu_0(k) = \sum_{i=0}^k \frac{i \cdot p_i}{\omega_0(k)} \quad (4)$$

$$\mu_1(k) = \sum_{i=k+1}^{L-1} \frac{i \cdot p_i}{\omega_1(k)} \quad (5)$$

2.3 Média Global da Imagem

A média de intensidade de toda a imagem (μ_T) é constante e independente do limiar k :

$$\mu_T = \sum_{i=0}^{L-1} i \cdot p_i \quad (6)$$

É fácil demonstrar a seguinte relação fundamental entre as médias:

$$\omega_0(k)\mu_0(k) + \omega_1(k)\mu_1(k) = \mu_T \quad (7)$$

3 O Critério de Otimização (A Variância Entre Classes)

Otsu definiu que o limiar ideal k^* é aquele que maximiza a **variância entre as classes** (σ_B^2). A variância mede a dispersão; maximizá-la entre as classes significa forçar a média do fundo e a média do objeto a ficarem o mais distantes possível uma da outra.

A fórmula matemática para a variância entre classes é:

$$\sigma_B^2(k) = \omega_0(k)(\mu_0(k) - \mu_T)^2 + \omega_1(k)(\mu_1(k) - \mu_T)^2 \quad (8)$$

Substituindo a relação da média global (μ_T) na equação acima e simplificando algebricamente, chegamos a uma forma muito mais elegante e computacionalmente vantajosa:

$$\sigma_B^2(k) = \omega_0(k)\omega_1(k) [\mu_0(k) - \mu_1(k)]^2 \quad (9)$$

Como $\omega_1(k) = 1 - \omega_0(k)$, podemos reescrever tudo em função de C_0 e da média acumulada até k , o que evita recalcular o somatório de C_1 a cada iteração do algoritmo.

—

4 O Algoritmo na Prática

O algoritmo de Otsu funciona por **força bruta inteligente**. Como o número de níveis de cinza (L) é pequeno (geralmente 256), o computador pode testar todos os valores possíveis de k de forma extremamente rápida.

1. Calcula o histograma e as probabilidades p_i da imagem.
2. Prepara as variáveis acumuladas e calcula a média global μ_T .
3. Para cada valor possível de limiar k de 0 a $L - 1$:
 - Atualiza $\omega_0(k)$ e $\mu_0(k)$.
 - Calcula $\omega_1(k)$ e $\mu_1(k)$.
 - Calcula a variância entre classes $\sigma_B^2(k)$.
4. O limiar ótimo k^* será aquele que resultou no maior $\sigma_B^2(k)$:

$$k^* = \arg \max_{0 \leq k < L-1} \sigma_B^2(k) \quad (10)$$

—

5 Tratamento de Múltiplos Valores Máximos

Quando o algoritmo encontra mais de um valor de k que maximiza a variância entre as classes (σ_B^2), significa que o histograma da imagem possui um “platô” de variância máxima. Isso ocorre quando existe um vale plano e bem definido entre os dois picos principais do histograma. Existem duas abordagens principais para resolver esse impasse:

5.1 A Abordagem Clássica (Média dos Limiares)

A recomendação matemática original de Otsu é calcular a **média aritmética** de todos os valores de k que atingiram o valor máximo de variância. Se os limiares ótimos formam um conjunto $K^* = \{k_1, k_2, \dots, k_m\}$, o limiar final escolhido será:

$$k^* = \frac{1}{m} \sum_{j=1}^m k_j \quad (11)$$

Essa abordagem posiciona o corte exatamente no centro geométrico do vale do histograma, garantindo estabilidade estatística.

5.2 A Abordagem Prática (Primeiro Encontrado)

Por questões de otimização de performance, muitas bibliotecas consagradas de processamento de imagens (como OpenCV e Scikit-Image) adotam uma estratégia direta: **mantêm o primeiro valor máximo encontrado** (o menor índice k).

```
1 # Abordagem comum (Fica com o primeiro maximo)
2 if var_entre_classes > max_var:
3     max_var = var_entre_classes
4     limiar_otimo = k
```

Listing 1: Lógica de atribuição padrão em bibliotecas.

Como o operador utilizado é o maior estrito ($>$), quaisquer picos subsequentes com o mesmo valor exato de variância máxima são ignorados. Para sistemas de tempo real, a diferença visual no resultado binarizado costuma ser imperceptível, tornando essa escolha a mais eficiente.

6 Exemplo Numérico Simplificado

Para fixar o conceito, imagine uma imagem hipotética minúscula com apenas **6 pixels** e apenas **4 níveis de cinza** (0, 1, 2, 3).

- **Histograma** (contagem de pixels por nível): $n_0 = 2, n_1 = 1, n_2 = 1, n_3 = 2 \Rightarrow N = 6$

- **Probabilidades** (p_i): $p_0 = \frac{2}{6}, p_1 = \frac{1}{6}, p_2 = \frac{1}{6}, p_3 = \frac{2}{6}$

- **Média Global** (μ_T):

$$\mu_T = \left(0 \cdot \frac{2}{6}\right) + \left(1 \cdot \frac{1}{6}\right) + \left(2 \cdot \frac{1}{6}\right) + \left(3 \cdot \frac{2}{6}\right) = \frac{0 + 1 + 2 + 6}{6} = \frac{9}{6} = 1.5$$

Vamos testar o limiar $k = 1$ (Classe $C_0 = \{0, 1\}$ e Classe $C_1 = \{2, 3\}$):

1. **Pesos:**

$$\omega_0 = p_0 + p_1 = \frac{2}{6} + \frac{1}{6} = \frac{3}{6} = 0.5$$

$$\omega_1 = 1 - 0.5 = 0.5$$

2. **Médias das Classes:**

$$\mu_0 = \frac{(0 \cdot p_0) + (1 \cdot p_1)}{\omega_0} = \frac{0 + \frac{1}{6}}{0.5} = \frac{1}{3} \approx 0.333$$

$$\mu_1 = \frac{(2 \cdot p_2) + (3 \cdot p_3)}{\omega_1} = \frac{\frac{2}{6} + \frac{6}{6}}{0.5} = \frac{\frac{8}{6}}{0.5} = \frac{8}{3} \approx 2.667$$

3. **Variância Entre Classes** $\sigma_B^2(1)$:

$$\sigma_B^2(1) = 0.5 \cdot 0.5 \cdot (0.333 - 2.667)^2 = 0.25 \cdot (-2.334)^2 \approx 1.362$$

O algoritmo repetiria esse cálculo para $k = 0$ e $k = 2$. O valor de k que maximizar $\sigma_B^2(k)$ será o escolhido.

—

7 Limitações do Método

Embora seja excelente, o método de Otsu assume que a imagem possui um **histograma bimodal** (dois picos claros). Ele pode falhar se:

- O ruído na imagem for muito alto (borrando a separação dos picos).
- A iluminação for não-uniforme (gradientes de luz), onde limiares adaptativos locais funcionam melhor.
- A proporção de tamanho entre o objeto e o fundo for excessivamente discrepante.